

Slováka Michala Valka z parížskeho DeepMindu považujú za svetovú špičku v strojovom učení

# Sme vedecký ústav na steroidoch

**N**a prestížnu Medzinárodnú konferenciu o strojovom učení (ICML) vo Viedni, ktorá sa koná tento týždeň, mu vzali až osem článkov, čo je druhý najväčší počet zo všetkých účastníkov z celého sveta.

Michal Valko hovorí, či sa dá naprogramovať intuícia a emócie, či sa v strojovom učení inšpirujú ľudským mozgom, a vysvetľuje, prečo môže mať aj umelá inteligencia predsudky.

**Na stránke DeepMind sa píše, že „umelá inteligencia by sa mohla stať jedným z najužitočnejších vynálezov ľudstva“. Prečo si to v spoločnosti myslíte?**

Pod umelou inteligenciou si každý predstavuje niečo iné. My si pod ňu predstavujeme systém, ktorý vie riešiť problémy. V DeepMinde sme pre verejnosť sprístupnili aj predpovede štruktúry niekoľkých málo skúmaných proteínov spojených s koronavírusom SARS-CoV-2. Využili sme najnovšiu verziu nášho systému AlphaFold. Medzi veľké problémy, ktoré by umelá inteligencia mohla vyriešiť, radíme napríklad nedostatok vody na planéte. Nemyslíme si, že umelá inteligencia vznikne z jednej vednej oblasti, preto máme v tíme ľudí, ktorí ovládajú matematiku, štatistiku, neurovedy a iné prírodné vedy. Odhadujem, že 30 percent ľudí v DeepMinde je z prírodných vied.

**Prečo je umelá inteligencia vhodná na riešenie takýchto problémov?**

Napríklad pri staročínskej hre Go našiel algoritmus umelej inteligencie ťahy, o ktorých ľudstvo ani nevedelo, že sú správne. Myslíme si, že niečo podobné by sa mohlo objaviť aj v iných oblastiach. Víziou DeepMindu je riešiť problémy, ktoré by si zaslúžili Nobelovu cenu. Zakladatelia DeepMindu si mysleli, že akademická obec postupuje pomerne pomaly a vývoj chceli urýchliť. Tak spojili vedcov s firmou. Inšpirovali sa v IBM či Microsofte. V spoločnosti ich oslobodili od povinností, ktoré by ich zťažovali na univerzite. Sme vedecký ústav na steroidoch, snažíme sa urýchliť vedu. Pracujem 12 až 16 hodín denne.

**Na akých projektoch pracujete v DeepMinde?**

Ostatný polrok som na projekte o takzvanom „self-supervised learning“, čo je strojové učenie bez spätnej väzby. Dosiť sme v umelej inteligencii dosiahli najväčšie úspechy vďaka tomu, že sme mali veľa dát, ktoré systému poskytovali veľa spätnej väzby. Lenže bežný život takto nefunguje – keď ideme doľava alebo doprava, nedostaneme spätnú väzbu, že je to zlé alebo dobré. Javy či veci nemajú „labels“, čiže značky, ktoré by napríklad dieťaťu 100-tisíckrát v rôznych situáciách povedali, že „toto je tvoja mama“, aby sa to naučilo.

**Vašou úlohou je zistiť, ako umelý systém naučiť čo najviac bez toho, aby mal spätnú väzbu?**

Presne tak. „Self-supervised learning“ je len drobná časť veľkého problému, ktorý voláme „reinforcement learning“. Pri ňom si systém vytvára vlastný súbor dát. V statických súboroch dát je presne stanovený zoznam vecí s určitou funkciou, ktorá sa nemení. V prípade „reinforcement learning“ je systém autonómny, vyberá si, či sa pozrie doľava, alebo doprava. Keď sa pozrie doľava, možno zmešká niečo užitočné vpravo. Cieľom je, aby sa systém učil robiť správne rozhodnutia.

**Čo je výsledkom učenia pri „reinforcement learning“?**

Výsledkom nie je „mačka“ alebo „pes“, „áno“ alebo „nie“, ale „choď doprava, a keď tam pôjdeš, niečo uvidíš a podľa toho sa zmeníš“. Je to aktívne učenie. V bežnom živote ľudia nedostávajú špeciálnu odmenu – nie je to tak, že idem doprava, lebo ma za to čaká odmena. No počítačové algoritmy fungujú obyčajne tak, že im nadizajnujeme odmenu. Preto riešime, ako sa správať, ak nemáme žiadnu odmenu, podobne ako v živote.

Predstavte si, že by som mal niečo nájsť. Prístupov, ktoré možno zvoliť, je veľa. Niektoré maximalizujú entropiu, že chceme byť všade rovnako veľa. Podľa iných sa chceme dostať do rohov, lebo tam môžu byť dvere, ktoré vás dostanú ďalej. Podľa iných sa mám riadiť pravidlom pravej ruky, takže pôjdem stále doprava. Je veľa možností a nevieme, ktorá je tá správna. Nevieme ani to, či niektorá z nich je správna. Tu vidím možnosť najväčšieho pokroku.

Pred pár dňami sme vydali článok o metóde BYOL (z angl.



Michal Valko (38)

Je odborník na strojové učenie. Na Fakulte matematiky, fyziky a informatiky UK vyštudoval odbor umelá inteligencia a matematické metódy v informatike. Doktorandské štúdium absolvoval na univerzite v Pittsburghu. V rokoch 2009 až 2010 bol na stáži v spoločnosti Intel v Silicon Valley. Momentálne pôsobí v akadémii vied v Lille. Učí na univerzite v Paríži a od roku 2019 je aj v spoločnosti DeepMind. Zaoberá sa „reinforcement learning-om“, čo je aktívny spôsob strojového učenia, kde sa algoritmy učia robiť správne rozhodnutia.

Bootstrap Your Own Latent). Je založená na tom, že pri rozhodovaní nepotrebuje žiadne príklady. Systém nemá pri tréningu nejakú špeciálnu spätnú väzbu, dostane len jednu stotinu možnej spätnej väzby, napriek tomu je úspešný v 79,6 percenta. Systémy sa snažíme navrhovať tak, aby sme do systému museli zasahovať čo najmenej.

**Spätná väzba je pre vás neúžitočná?**

Je veľmi užitočná, no problémom je, že je jej málo. Ľudia sa dokážu naučiť veľa z minimu spätnej väzby. Hra Go bola taká ťažká preto, lebo spätná väzba je nula, ak prehráte. Ak hráte s majstrom, prehráte vždy. Preto systém skoro vôbec nevie, na čom je. Pomocnou spätnou väzbou môže byť napríklad počet figúrok v šachu. V reálnom živote máme málo

spätnej väzby – kým nebude liek na koronavírus, spätná väzba je nula. Aby som to zhrnul, spätná väzba je super a dôvod, prečo robíme „self-supervised learning“ alebo „unsupervised learning“, je, že nás inšpiruje to, že aj keď ľudia mnohokrát nemajú spätnú väzbu, dokážu sa učiť. Aj keď sme v neznámom prostredí, vieme robiť niečo, čo je inteligentné.

**Vydali sme sa na cestu všeobecnej umelej inteligencie, ktorá nebude zvládať len jeden problém, ale celú sumu, podobne ako človek?**

Áno, hoci uvažujete dopredu. V DeepMinde sa venujeme aj riešeniu parciálnych problémov. Naposledy som robil na projekte, aby sa systém naučil nejakú reprezentáciu s tým, aby sa táto reprezentácia veľmi nezmenila aj v prípade, že na obrázku zmeníme farby alebo

ho prehádzame. Systém dokáže iba toto, iné veci nie. Neexistuje univerzálny systém, ktorý by dal ideálnu odpoveď vo všetkých prostrediach. Inak povedané, ku každému algoritmu existuje prostredie, v ktorom robí algoritmus niečo zle. Stále teda platí, že vieme vymyslieť len špeciálne algoritmy na riešenie konkrétnych problémov. Nevieme to, čo človek, ktorý vie šoférovať, čítať aj hrať hry.

S počítačovými hrami sme začali pracovať práve preto, lebo na nich možno dobre simulovať nejaké prostredie. Algoritmus sa naučí jednu hru a môže ju hrať veľmi dobre. Oveľa ťažšie je, aby ten istý algoritmus hral dobre aj inú hru. Len pred pár mesiacmi sme v DeepMinde vydali algoritmus Agent57, ktorý hrá 57 hier Atari lepšie ako človek. No schopnosti Agent57 nesiahajú ďalej. Vie hrať len tie hry. Množinu problémov, ktoré algoritmus zvládne, sa snažíme stále rozširovať, aby sme ho jedného dňa postavili pred problém, ktorý my vyriešiť nevieme, no on by na to mohol prísť. Ide napríklad o zlepšenie uchovávaní energie v baterkách. Alebo iný problém, ktorého riešenie by ľudstvo posunulo vpred. Napríklad pre Google sme spravili systém na chladenie serverov, ktorý znížil spotrebu energie o 40 percent.

**Víziou DeepMindu je riešiť problémy, ktoré by si zaslúžili Nobelovu cenu.**